

También, es usual expresar el rendimiento en términos de OP/s (operaciones por segundo), que corresponde solamente a dividir la frecuencia por el CPI:

$$P = \frac{f}{\text{CPI}} \quad (1.5)$$

Ley de Amdahl

La ley de Amdahl es una formulación del rendimiento que indica cuál va a ser la ganancia (en veces) de un programa o carga de trabajo si se paraleliza el código.




Figura 1.28: Ley de Amdahl expresando los porcentajes de código no paralelizable vs código paralelizable

Hay dos aspectos fundamentales que formula Amdahl:

1. El código se compone de dos partes: parte paralelizable y parte serial (no se puede paralelizar)
2. Solo se puede paralelizar la parte paralelizable hasta converger al consumo de la parte serial.

Esto implica que vamos a topar con un límite en el que ya no podemos acelerar más una carga de trabajo, tal como se ilustra en la Figura 1.28. Vamos a comenzar con la formulación matemática de la mejoría de una carga de trabajo, que es:

$$S = \frac{T_1}{T_p} \quad (1.6)$$

donde S es el *speedup*, T_1 es el tiempo original para procesar cada dato individualmente o con un único procesador, y T_p es el tiempo después de agregar paralelismo p .

Ahora, la ley de Amdahl establece que el tiempo de ejecución con mejora va a tener dos componentes, una serial T_s y otra paralelizable T_p :

$$T_n = T_s + T_p \quad (1.7)$$

Generalmente, las cargas de trabajo pueden fragmentarse en dos clases: parte paralelizable y parte serial. Para ello, podemos decir que la proporción paralelizable cumple con los siguientes criterios:

$$p = 1 - s \quad (1.8)$$

donde p es la proporción paralelizable y s es la proporción serial. Ambas variables rondan de 0 a 1. Esto permite derivar lo siguiente:

$$T_n = T_1 \times \left(s + \frac{p}{n}\right) \quad (1.9)$$

que en este caso, el tiempo de ejecución mejorado T_n va a estar compuesto por la proporción serial de T_1 y por la proporción paralelizable paralelizada n veces.

Conectando con la ecuación de escalamiento o mejora:

$$S = \frac{1}{s + \frac{p}{n}} \quad (1.10)$$

Finalmente, para determinar la eficiencia de un sistema, tenemos la expresión:

$$\eta = \frac{S}{n} \quad (1.11)$$

donde la eficiencia η está dada por el speedup entre la cantidad de paralelismo agregado.

Roofline model

Es una herramienta visual y conceptual muy usada en arquitectura de computadores y optimización de rendimiento (especialmente en HPC, GPU y sistemas vectoriales). Sirve para evaluar y entender los límites teóricos de rendimiento de un programa en función del hardware (ver Figura 1.29).

En el eje X vamos a tener la cantidad de operaciones matemáticas que se realizan sobre un conjunto de datos. Se mide como OP/byte, que resulta ser el cociente entre la cantidad de operaciones y el volumen de datos.

En el eje Y vamos a tener la cantidad de operaciones realizadas por unidad de tiempo. En este caso, contabilizamos el total de operaciones durante el tiempo que se tarda en ejecutarlas.